

Índice general

Modelado final: consolidación de los tres análisis independientes1

Resumen1

1. Objetivo y alcance2

2. Datos de partida2

3. Protocolo experimental3

4. El modelo entregado4

5. Resultados por etapa5

6. Test ciego sobre 2023: pendiente y deliberado9

7. Limitaciones declaradas10

8. Reproducibilidad10

9. Componentes integrados11

Modelado final: consolidación de los tres análisis independientes

Sistema de predicción de igniciones forestales en Galicia Fase de modelado ·
Documento de cierre · 5 de septiembre de 2026

Resumen

Este documento describe el pipeline definitivo de modelado, que consolida en un único punto de entrada reproducible los tres análisis que el equipo había realizado por separado sobre el dataset EGIF. Sustituye a los estudios previos como referencia para el capítulo de modelado de la memoria.

El modelo entregado es un **LightGBM sobre 48 predictores**, entrenado sobre 2016-2020, calibrado con regresión de Platt y validado sobre el año 2022 completo sin submuestrear.

Métrica	Valor
Recall con el 5 % del territorio en alerta	39,66 % (IC 90 %: 37,67 – 41,71)
Recall en el 1 % de celdas más críticas del día	7,66 %
ROC-AUC global	0,8659
ROC-AUC en temporada (junio-septiembre)	0,8052
ROC-AUC dentro del día	0,7431
PR-AUC	0,00141 (lift 9,18× sobre azar)
Filas evaluadas	10.804.365
Igniciones	1.659 (prevalencia 0,0154 %)

El resultado principal para la memoria: el modelo supera a las **dos** versiones del índice FWI disponibles. Frente al oficial de Copernicus CEMS, +17,2 puntos, equivalentes a **286 igniciones adicionales al año** con el mismo presupuesto de vigilancia; frente al calculado a 1 km con las ecuaciones de Van Wagner, +15,7 puntos y 261 igniciones.

El resultado metodológicamente más relevante: una variante que solo emplea información disponible al terminar el día anterior alcanza el 39,54 % de recall, **estadísticamente indistinguible del modelo completo** (0,12 puntos de diferencia frente a un suelo de ruido de 1,93). El sistema no es únicamente un índice de diagnóstico: funciona como aviso anticipado sin coste medible.

1. Objetivo y alcance

El equipo había producido tres análisis independientes sobre el mismo dataset, con protocolos y conclusiones parcialmente divergentes. Este trabajo tenía tres objetivos:

1. **Unificar** los tres en un pipeline único, reproducible con un solo comando.
2. **Resolver las discrepancias** entre ellos, en particular el conflicto sobre el método de calibración, que producía diferencias de más de seis puntos de recall.
3. **Cerrar las objeciones metodológicas** pendientes con evidencia medida, no con argumentos.

El resultado es `scripts/pipeline_definitivo.py`: trece etapas que se ejecutan de forma ordinaria y producen tanto el modelo de producción como la evidencia que lo respalda, más una decimocuarta —el test ciego— que solo se activa a petición expresa.

2. Datos de partida

El dataset procede del datacubo canónico, reconstruido el 5 de septiembre de 2026 con la serie histórica completa, en formato Parquet particionado por año.

Concepto	Valor
Predictores declarados	50
Años disponibles	2016-2023
Filas totales	86.494.122
Igniciones registradas	12.699
Filas descartadas por predictores incompletos	0
Contrato temporal	Sin desfase; los acumulados incluyen la fecha T
Codificación cíclica del calendario	Ninguna

Los 50 predictores se agrupan en cuatro familias temáticas: meteorología (22), topografía (12), cobertura del suelo (9) y actividad humana (7).

La ausencia de variables de calendario es deliberada y se comprueba en la etapa contrato. Un modelo que dispusiera de la fecha podría alcanzar buenas métricas globales limitándose a aprender la estacionalidad, sin extraer información meteorológica alguna.

2.1 Auditoría de integridad previa

Antes de entrenar se verificó la coherencia interna del dataset:

- **Sin fugas del target.** Ningún predictor deriva de la variable objetivo. Las columnas de resultado (`burned_area_ha`, `large_fire_500ha`, `target_ignicion`) y la auxiliar de muestreo (`is_near_ignition_25x25_10d`) están declaradas fuera del conjunto de predictores y el contrato lo verifica al cargar.
- **Coherencia física del déficit de presión de vapor.** `vpd_mean` y `vpd_max_12_18h` cuadran con la formulación de Magnus aplicada a la temperatura y la humedad de su propia fila (correlaciones de 0,9944 y 0,9999).
- **Relaciones de orden.** $\text{Mínimo} \leq \text{media} \leq \text{máximo}$ en temperatura, humedad y viento; los extremos de la ventana 12-18 h contenidos en el rango del día completo. Se cumplen en los 10,8 millones de filas de 2022 **sin una sola excepción**.

2.2 Incidencia detectada y corregida: `consecutive_dry_days`

Sobre la versión anterior del datacubo, la auditoría detectó que una de las tres variables acordadas en la reunión del 29 de agosto no era reproducible a partir del resto de la fila. Los días consecutivos sin lluvia significativa presentaban tres anomalías incompatibles con su definición:

Anomalía	Alcance (año 2022)
Valores no enteros, siendo una cuenta de días	11,25 % de las filas
Celda sin lluvia en su propia columna y contador que desciende	42.550 celda-día
Lluvia superior a 1 mm y contador que no se reinicia	123.935 celda-día

Causa. La variable se calcula sobre la rejilla original de ERA5-Land (≈ 9 km) y después se interpola espacialmente a la rejilla de 1 km. La interpolación conmuta con las operaciones lineales pero no con las que dependen de la historia: promediar la racha de una celda que lleva un mes seca con la de su vecina, a la que llovió el día anterior, no produce la racha de ninguna de las dos. Las otras dos variables acordadas —medias móviles de humedad y viento— sí sobreviven a la interpolación, y de hecho coinciden con el recálculo independiente hasta el límite de la precisión de coma flotante simple.

Solución. El pipeline de ingesta se corrigió para derivar la racha al final del proceso, a partir de la precipitación ya interpolada a cada celda de 1 km. La versión vigente del datacubo publica un contador entero, coherente con la lluvia de su propia fila y con continuidad entre años. La incidencia queda resuelta en origen.

Salvaguarda permanente. `src/entrenamiento/dias_secos.py` conserva la reparación para Parquet heredados, y el pipeline **diagnostica la columna al arrancar**: mide la proporción de valores no enteros y de días con lluvia que no reinician el contador, y solo repara si detecta el patrón. Sobre el datacubo actual el diagnóstico da 0,00 % en ambos síntomas y la columna no se toca. Así la decisión no depende de que nadie recuerde qué versión del dataset tiene delante.

3. Protocolo experimental

3.1 Separación temporal de los años

Año	Papel	Igniciones
2016–2020	Entrenamiento	9.584
2021	Parada temprana y ajuste del calibrador	926
2022	Validación: conjunto sobre el que se tomaron las decisiones	1.659
2023	Test ciego: no interviene en ninguna decisión	530

El periodo de entrenamiento se amplió a cinco años al reconstruir el datacubo. Antes de adoptarlo se comprobó que el registro EGIF no estuviera infrarregistrado en los años nuevos: 2016 y 2017 son, de hecho, los peores de la serie (2.246 y 2.980 igniciones frente a las 1.659 de 2022), de modo que aportan comportamiento de fuego extremo que el modelo no había visto.

El año reservado, 2023, es el más flojo de la serie con 530 igniciones. Sus intervalos de confianza serán por tanto más anchos que los de validación, y así debe advertirse al reportarlo.

La separación es temporal y no aleatoria. Un reparto aleatorio de filas colocaría días consecutivos de la misma ola de calor a ambos lados de la partición, y el modelo obtendría métricas excelentes sin haber aprendido nada transferible a un año futuro.

3.2 Submuestreo de negativos y corrección de prior

Con una prevalencia del 0,0154 %, los días-celda sin ignición son masivamente redundantes. Se conservan **todas las igniciones y uno de cada cien negativos**, seleccionados mediante

un hash determinista de (`cell_id`, `fecha`) para que la muestra sea reproducible y estable entre ejecuciones.

El factor de submuestreo se adoptó a partir de la medición del análisis independiente que comparó dieciséis combinaciones y estableció que 1/100 produce un recall indistinguible de 1/25 con un cuarto del coste de entrenamiento.

El submuestreo infla las probabilidades predichas en un factor conocido, que se deshace con la corrección de prior de King y Zeng antes de calibrar. **La evaluación nunca se submuestrea**: se realiza sobre la población completa del año, y una comprobación de cobertura aborta la ejecución si el recorrido no cubre exactamente las filas que declara el contrato.

3.3 Calibración: por qué Platt y no isotónica

Dos de los tres análisis previos discrepaban en este punto: uno no observaba efecto al calibrar y el otro perdía más de seis puntos de recall.

La causa es que la regresión isotónica es una función **escalonada**: asigna valores idénticos a bloques enteros de observaciones. Sobre diez millones de filas eso genera millones de empates, y cualquier umbral definido por percentiles —como el del 5 % del territorio— cae en mitad de un escalón y desplaza el corte de forma arbitraria. El primer análisis no lo sufría porque calculaba las métricas de ordenación sobre la puntuación cruda, antes de calibrar; el segundo aplicaba la isotónica a la probabilidad de decisión y por eso se degradaba.

La regresión de Platt resuelve la discrepancia por ser estrictamente monótona: no introduce empates, el orden de las celdas es idéntico antes y después de calibrar, y ranking y probabilidad calibrada pasan a ser la misma magnitud. El sistema puede así operar sobre un único número.

El calibrador se ajusta sobre 2021, un año que el modelo no ha visto y con su prevalencia real intacta. Ajustarlo dentro de la muestra de entrenamiento reproduciría el sobreajuste en lugar de corregirlo.

3.4 Métricas y por qué estas

La exactitud (*accuracy*) no aparece en ningún punto del trabajo: un modelo que predijera ausencia de fuego todos los días acertaría el 99,985 % de las veces. Las métricas empleadas responden a la pregunta operativa real.

- **Recall a coste operativo fijo ($FPR \leq 5\%$).** Fracción de igniciones capturadas si se vigila de forma reforzada el 5 % del territorio. Presupuesto fijo, realista e interpretable sin formación estadística.
- **Recall en el 1 % diario.** La misma idea aplicada día a día: las 296 celdas más críticas de cada jornada. Más exigente y más próximo al despliegue real de medios.
- **ROC-AUC en tres versiones.** Global, restringido a temporada (junio-septiembre) y calculado dentro de cada día y promediado. La progresión $0,8659 \rightarrow 0,8052 \rightarrow 0,7431$ es informativa: mide cuánto del rendimiento procede de distinguir agosto de enero —algo que el calendario ya resuelve— y cuánto de discriminar celdas dentro de un mismo día, que es la aportación real.
- **Intervalos de confianza al 90 % por bootstrap sobre las igniciones**, no sobre todas las filas: la incertidumbre procede casi por completo de los 1.659 positivos.

4. El modelo entregado

LightGBM sobre 48 de los 50 predictores. Quedan excluidas `precipitation_sum` y `consecutive_dry_days`.

4.1 Justificación de la exclusión

La versión de 48 variables obtiene 39,66 % de recall frente al 39,12 % del conjunto completo. **Esa diferencia de 0,54 puntos no justifica la decisión:** es muy inferior al suelo de ruido de 1,93 puntos que establece la etapa semilla, por lo que ambas versiones son estadísticamente indistinguibles. Presentar la diferencia como una mejora sería interpretar ruido, y además la comparación se realizó sobre el conjunto de validación, lo que la invalidaría como criterio de selección.

El criterio aplicado es otro: a igualdad de rendimiento se elige la versión que no admite la objeción. Ambas variables contienen la precipitación del propio día T, que en muchos casos es posterior a la ignición. Prescindir de ellas no tiene coste medible y elimina la crítica más seria que puede formularse contra el contrato temporal del dataset. Es una decisión metodológica, no un ajuste a los datos.

La configuración queda registrada en el parámetro `excluir_del_modelo` y se serializa junto con el modelo, de modo que cualquier consumidor futuro puede verificar qué variables se usaron y por qué se descartaron las restantes.

4.2 Hiperparámetros

No se realizó búsqueda de hiperparámetros. Dos de los tres análisis previos midieron que el ajuste fino aporta menos que el ruido de implementación, por lo que se emplean valores estables y se documenta la decisión: 800 árboles como techo, tasa de aprendizaje 0,05, 63 hojas, mínimo 30 observaciones por hoja, submuestreo de filas y columnas al 80 %, y parada temprana a 50 rondas sobre el año de calibración.

Se fija `deterministic` y `force_row_wise` para que la ejecución sea reproducible.

5. Resultados por etapa

5.1 Selección de algoritmo (modelos, pareado)

Se entrenaron cuatro candidatos con protocolo idéntico. La regresión logística se incluye deliberadamente: si el *boosting* no le sacara ventaja sustancial, lo correcto sería entregar el modelo lineal, interpretable y explicable en dos frases.

Modelo	Recall @5 %	Recall 1 % diario	ROC dentro del día
LightGBM	39,66 %	7,66 %	0,7431
XGBoost	35,74 %	7,11 %	0,7321
Random Forest	34,00 %	7,11 %	0,6903
Regresión logística	30,98 %	3,98 %	0,7011

La comparación se completó con el test pareado sobre las mismas igniciones y el estadístico de McNemar. LightGBM supera a los otros tres de forma concluyente:

Comparación	Diferencia	p (McNemar)
LightGBM vs. regresión logística	+8,68 pp	$6,4 \cdot 10^{-16}$
LightGBM vs. Random Forest	+5,67 pp	$1,1 \cdot 10^{-6}$
LightGBM vs. XGBoost	+3,92 pp	$1,8 \cdot 10^{-4}$

Las diferencias superan el suelo de ruido de 1,93 puntos. **Conviene señalar que esto corrige una conclusión anterior:** análisis previos sobre versiones distintas del dataset habían encontrado empate entre LightGBM y XGBoost. Con el dataset de 50 predictores no lo hay.

5.2 Estabilidad frente a la semilla (semilla)

Cinco reentrenamientos idénticos salvo por la semilla aleatoria:

Semilla	Recall @5 %	Recall 1 % diario
42	39,66 %	7,66 %
7	39,60 %	8,38 %
123	39,42 %	8,44 %
2024	39,96 %	8,50 %
31	41,35 %	8,86 %

Dispersión: 1,93 puntos de recall, equivalentes a 32 igniciones. Este valor es el suelo de ruido del estudio y condiciona la lectura de todas las demás etapas: ninguna diferencia inferior a 1,93 puntos puede presentarse como un hallazgo. Es un listón exigente y conviene que lo sea.

Sin esta medición, cualquier comparación del trabajo sería ininterpretable.

5.3 Circularidad temporal (circularidad)

El dataset no aplica desfase temporal: la meteorología corresponde al propio día de la ignición, y la precipitación diaria agrega las 24 horas completas. Una ignición declarada a las 15:00 convive en su fila con la lluvia caída a las 22:00. Es la objeción de mayor calado que admite el diseño del dataset.

Una respuesta limitada a retirar las dos variables más evidentes sería incompleta, porque **todos los acumulados incluyen la fecha T por construcción** —incluida precipitation_sum_3d, la variable de mayor importancia del modelo—. Se midieron por tanto tres escenarios de exigencia creciente:

Escenario	Variables	Recall @5 %	ROC dentro del día
Modelo entregado	48	39,66 %	0,7431
Pronóstico (solo hasta T-1)	36	39,54 %	0,7344
Completo (incluye el día T)	50	39,12 %	0,7400
Amplia (sin ningún acumulado)	40	36,23 %	0,7413

El escenario de pronóstico merece detalle. Los acumulados pueden despojarse del día T mediante aritmética exacta sobre las columnas publicadas: una suma de siete días que incluye hoy, menos el valor de hoy, **es** la suma de los seis días anteriores; una media de siete días multiplicada por siete, menos el valor de hoy, dividida entre seis, **es** la media de los seis anteriores. La transformación se verificó contra ejemplos calculados a mano. Retirando además toda observación del propio día quedan 36 variables que solo contienen información disponible al terminar el día T-1.

Ese modelo alcanza el 39,54 % de recall, a 0,12 puntos del modelo completo. La diferencia es un orden de magnitud menor que el suelo de ruido de 1,93: son estadísticamente indistinguibles.

La implicación es sustantiva. Renunciar por completo a los datos del día que se predice **no tiene coste medible**, de modo que el sistema no se limita a describir el día en curso: puede emitir el aviso la tarde anterior, que es el horizonte que un servicio de extinción necesita para movilizar medios, y sigue superando a las dos versiones del FWI por más de quince puntos.

Y responde a la objeción del contrato temporal de forma definitiva: aun rechazando de plano el uso de información del propio día, las conclusiones del trabajo se mantienen intactas. Merece la pena señalar que con el periodo de entrenamiento anterior esta variante perdía 2,1 puntos; al disponer de cinco años de entrenamiento la pérdida desaparece.

5.4 Comparación con el estándar operativo (fwi)

Superar a una regresión logística demuestra únicamente que el *boosting* supera a un modelo lineal. Para sostener que el sistema aporta valor sobre lo que ya se publica es necesario compararlo con el **Fire Weather Index** del sistema canadiense (CFFDRS), que es el índice que difunden AEMET y EFFIS y el que se emplea operativamente.

El FWI se calculó a resolución de 1 km sobre nuestro propio dataset, con las ecuaciones de Van Wagner, en lugar de descargarlo de CEMS a 27,5 km e interpolarlo. El resultado es un baseline más exigente que el de la referencia bibliográfica.

Se evalúan las dos fuentes del índice de que dispone el proyecto, porque cada una tiene una limitación distinta y ninguna por separado cierra la discusión. El **oficial de CEMS** está calculado como manda la definición, pero nace a 27,5 km: al interpolarlo a 1 km, todas las celdas bajo un mismo píxel comparten valor y no puede discriminar dentro de él. El de **Van Wagner a 1 km** sí distingue celda a celda, pero sustituye la lectura de mediodía por los extremos de la ventana 12-18 h.

	Recall @5 %	ROC dentro del día	Ventaja del modelo
Modelo	39,66 %	0,7431	—
FWI Van Wagner 1 km	23,93 %	0,6148	+15,7 pp · 261 igniciones/año
FWI oficial CEMS	22,42 %	0,6015	+17,2 pp · 286 igniciones/año

Superar a las dos cierra a la vez las dos réplicas posibles: que la ventaja proceda únicamente de disponer de mayor resolución, y que el índice con el que se compara no sea el que realmente se publica.

Salvedad que debe constar en la memoria: el FWI oficial se define sobre observaciones de mediodía solar, mientras que aquí se calcula con los extremos de la ventana 12-18 h. Esa sustitución sobreestima el índice de forma sistemática. Es aceptable para su uso como baseline comparativo —interesa su capacidad de ordenar celdas por riesgo, no su valor absoluto—, pero invalida el uso de los umbrales oficiales de la tabla de peligro.

5.5 Contribución de las variables (importancia)

Importancia por permutación (caída de ROC-AUC al barajar cada variable, tres repeticiones):

Variable	Caída de ROC-AUC
precipitation_sum_3d	0,0265
relative_humidity_mean_7d	0,0216
elevation_mean	0,0120
vpd_mean	0,0108
road_length_local_km	0,0106
precipitation_sum_7d	0,0102

La presencia de `road_length_local_km` entre las primeras es coherente con la etiología conocida de los incendios en Galicia, de origen humano en su gran mayoría.

Ablación por grupos temáticos (un entrenamiento completo por grupo retirado):

Grupo retirado	Variables restantes	Recall @5 %	Δ
Meteorología	28	25,92 %	−13,74 pp
Topografía	36	37,49 %	−2,17 pp
Actividad humana	41	38,76 %	−0,90 pp
Cobertura del suelo	39	39,18 %	−0,48 pp

Grupo retirado	Variables restantes	Recall @5 %	Δ
Ninguno	48	39,66 %	—

La meteorología es el núcleo del modelo: sin ella el recall cae más de trece puntos. La topografía aporta 2,17 puntos, por encima del suelo de ruido de 1,93 y por tanto demostrable.

Actividad humana y cobertura del suelo quedan por debajo del suelo de ruido (0,90 y 0,48 puntos): su contribución no es distinguible de la variación aleatoria. Son dieciséis variables cuya aportación el estudio no puede demostrar. Conviene enunciarlo así —«no demostrable»— y no como «no aportan nada», que es una afirmación más fuerte de lo que el dato sostiene.

5.6 Generalización espacial (espacial)

Es la prueba más exigente del conjunto. Un modelo puede obtener métricas excelentes limitándose a memorizar qué celdas arden con regularidad —los montes de Ourense arden todos los años— sin haber aprendido relaciones meteorológicas transferibles. Ese modelo funcionaría en Galicia y en ningún otro sitio.

El territorio se divide en cinco **bandas diagonales**, se entrena excluyendo una banda completa y se evalúa exclusivamente sobre ella. Las bandas son diagonales y no cuadrantes norte-sur porque Galicia presenta un gradiente climático acusado entre la costa atlántica y el interior ourensano: unos cuadrantes dejarían algún pliegue sin litoral y el modelo fallaría por no haber visto ese régimen climático, no por incapacidad de generalizar.

Banda	Igniciones	Recall @5 %	ROC dentro del día
0	646	26,01 %	0,5920
1	442	28,96 %	0,6705
2	253	24,90 %	0,6557
3	166	27,11 %	0,6361
4	152	29,61 %	0,5869

ROC dentro del día: 0,7431 con el reparto habitual, 0,6282 en territorio no visto. La caída de 0,115 debe declararse explícitamente en la memoria: cuantifica la fracción del rendimiento que **no se transfiere** a una zona no representada en el entrenamiento. El sistema está validado para Galicia; su despliegue en otra comunidad exigiría reentrenamiento.

5.7 Análisis de errores (errores)

Un recall del 38 % implica que seis de cada diez igniciones no se detectan. Identificar **cuáles** es lo que distingue un modelo de un sistema operativo.

Mes	Igniciones	Recall
Enero	115	42,61 %
Febrero	139	40,29 %
Marzo	72	0,00 %
Abril	94	18,09 %
Mayo	116	21,55 %
Junio	50	2,00 %
Julio	428	55,37 %
Agosto	491	48,07 %
Septiembre	122	25,41 %
Octubre	29	20,69 %

El rendimiento se concentra donde importa: julio y agosto acumulan 919 de las 1.659 igniciones y el modelo detecta más de la mitad en julio. El fracaso de marzo —**cero de setenta y dos**— es coherente con la etiología: las igniciones de marzo proceden mayoritariamente de quemas agrícolas descontroladas, un fenómeno cultural y de calendario laboral que el modelo no observa, ya que solo dispone de meteorología, terreno y vegetación.

Las igniciones no detectadas se producen sistemáticamente en días **más húmedos, más frescos y con menos días secos acumulados** que las detectadas, lo que confirma que el modelo ordena por severidad meteorológica y que lo que se le escapa son los fuegos cuyo origen no es meteorológico.

5.8 Calibración y niveles de riesgo (fiabilidad, riesgo)

La tabla de fiabilidad, sobre doce tramos de igual tamaño, muestra correspondencia monótona entre probabilidad predicha y frecuencia observada, con **infraestimación sistemática en torno a un factor 1,4** (tramo superior: $6,89 \cdot 10^{-4}$ predicho frente a $9,47 \cdot 10^{-4}$ observado). La salida es apta para ordenar y para fijar umbrales; no debe interpretarse como probabilidad absoluta sin advertirlo.

Traducción a niveles operativos, por cuantiles de la probabilidad calibrada:

Nivel	% del territorio	Celdas-día	Igniciones	Incidencia	Veces sobre «Bajo»
Bajo	90,0 %	9.723.928	735	$7,6 \cdot 10^{-5}$	1,0
Moderado	8,0 %	864.349	526	$6,1 \cdot 10^{-4}$	8,1
Alto	1,5 %	162.066	238	$1,5 \cdot 10^{-3}$	19,4
Extremo	0,5 %	54.022	160	$3,0 \cdot 10^{-3}$	39,2

Lo relevante no es la posición de los cortes sino que la incidencia observada crece de forma marcada y monótona entre niveles. Es lo que permite a quien recibe el aviso confiar en que «extremo» designa una situación cualitativamente distinta de «alto».

5.9 Sensibilidad a la definición del objetivo (target)

El registro EGIF contabiliza toda ignición, incluidos conatos de escasa superficie. Reevaluando el mismo modelo sobre subconjuntos definidos por superficie quemada:

Definición	Igniciones	Recall @5 %	ROC dentro del día
Todas	1.659	39,66 %	0,7431
≥ 1 ha	351	38,18 %	0,6919
≥ 10 ha	106	35,85 %	0,6306
≥ 100 ha	29	27,59 %	0,6077
≥ 500 ha	12	25,00 %	0,4529

El recall se mantiene razonablemente estable hasta las 10 ha, lo que indica que el modelo no debe su rendimiento a acertar conatos irrelevantes, aunque descende en los estratos superiores. **En el de grandes incendios el ROC dentro del día cae a 0,4529, por debajo del azar**; debe reportarse, si bien con la cautela que impone un tamaño de muestra de doce casos, insuficiente para sostener conclusión alguna.

6. Test ciego sobre 2023: pendiente y deliberado

El año 2023 no ha intervenido en ninguna etapa de este trabajo.

La razón es que las cifras de 2022, siendo el modelo ciego a ese año, **no lo son respecto al proceso de decisión**: la elección del algoritmo entre cuatro candidatos, la exclusión

de dos variables y la fijación del umbral operativo se resolvieron examinando resultados sobre 2022. Toda decisión adoptada a la vista de un conjunto lo incorpora parcialmente al entrenamiento, y sesga sus métricas al alza.

2023 proporciona la única estimación insesgada del rendimiento en producción, y solo la proporciona si se emplea **una única vez**, con la configuración enteramente congelada — algoritmo, hiperparámetros, conjunto de variables, protocolo de muestreo y calibrador—. Por eso la etapa correspondiente no se ejecuta por defecto y exige el argumento explícito `--abrir-test-ciego`.

Compromiso metodológico: el resultado que arroje esa ejecución se reportará sin modificaciones. No se revisará el modelo a la vista de él; hacerlo convertiría 2023 en un segundo conjunto de validación y agotaría el último año no contaminado del dataset.

En la memoria, la cifra de 2023 constituye el rendimiento esperado del sistema; la de 2022 documenta el proceso de selección.

7. Limitaciones declaradas

Se enumeran de forma explícita por integridad metodológica:

1. **Generalización espacial limitada.** El ROC dentro del día desciende de 0,7431 a 0,6282 en territorio no representado en el entrenamiento. El sistema está validado para Galicia.
 2. **Igniciones de origen no meteorológico.** El recall es nulo en marzo (0 de 72) y del 2 % en junio, cuando predominan las quemas agrícolas. El modelo no dispone de variables que capturen ese fenómeno.
 3. **Grandes incendios.** Sin capacidad demostrada de discriminación en el estrato de más de 500 hectáreas, aunque con una muestra de doce casos que no permite concluir.
 4. **Calibración conservadora.** Infraestima el riesgo en torno a un factor 1,4; apta para ordenación y umbrales, no para lectura como probabilidad absoluta.
 5. **Aportación no demostrable de dos familias de variables.** Actividad humana y cobertura del suelo quedan por debajo del suelo de ruido en la ablación. No se afirma que sobren, sino que este estudio no puede demostrar su contribución.
 6. **FWI sobreestimado.** El baseline se calcula con extremos de la ventana 12-18 h en lugar de observaciones de mediodía solar. Válido como ordenación, no para las categorías oficiales.
 7. **Un único año de validación.** Las conclusiones se apoyan en 2022; una validación cruzada temporal sobre varios años reduciría la incertidumbre, a costa de consumir el año reservado.
 8. **Año ciego pequeño.** 2023 es el año más flojo de la serie (530 igniciones), de modo que la estimación insesgada que produzca tendrá intervalos más anchos que los de validación.
-

8. Reproducibilidad

Ejecución

```
conda activate incendios-forestales
python scripts/pipeline_definitivo.py                # las trece etapas ordinarias
python scripts/pipeline_definitivo.py --etapas modelos,fwi
python scripts/pipeline_definitivo.py --rehacer      # ignora resultados previos
python scripts/pipeline_definitivo.py --abrir-test-ciego # solo al cerrar, una vez
```

Cada etapa guarda su tabla y se omite si el fichero ya existe, de modo que una ejecución interrumpida se retoma donde estaba. Tiempo total aproximado: 30 minutos sobre el periodo 2016-2023.

Artefactos

Ruta	Contenido
scripts/pipeline_definitivo.py	Pipeline completo: trece etapas más el test ciego
src/entrenamiento/dias_secos.py	Diagnóstico y reparación de consecutive_dry_days
src/entrenamiento/platt.py	Calibrador, en módulo propio para que el modelo sea portable
data/models/modelo_definitivo.pkl	Modelo, calibrador, variables y configuración
docs/technical/pipeline_*.csv	Una tabla por etapa
docs/technical/importancia_permutacion.csv	Importancia de las 48 variables
docs/technical/errores_por_mes.csv	Recall mensual
docs/technical/umbrales_riesgo.json	Cortes de los cuatro niveles
docs/technical/pipeline_definitivo_config.json	Configuración completa de la ejecución

La configuración se serializa junto al modelo, de modo que cualquier resultado puede rastrearse hasta los parámetros exactos que lo produjeron.

Verificación del propio pipeline

Antes de ejecutarlo sobre los datos reales, todas las etapas se validaron sobre un dataset sintético en miniatura con esquema idéntico al real. La prueba no se limitó a comprobar que el código no falla: los datos sintéticos se construyeron con señal inyectada en una única variable, y las etapas de importancia y ablación la identificaron correctamente, verificando que miden lo que declaran medir. El procedimiento detectó dos defectos de integración que fueron corregidos.

9. Componentes integrados

El pipeline no se escribió de cero: reutiliza los desarrollos que el proyecto ya tenía y añade lo necesario para cerrar las objeciones pendientes. Se detalla la procedencia de cada bloque para que quede trazable qué es reutilización y qué es aportación nueva de esta fase.

Componente	Procedencia
Librería de entrenamiento, métricas a coste operativo fijo, comparación pareada con McNemar, selección de variables, tabla de fiabilidad	Línea de modelado supervisado del proyecto
Baseline FWI, comparación de cuatro algoritmos, análisis de errores, sensibilidad a la definición del objetivo, planteamiento de la circularidad, factor de submuestreo 1/100	Línea de análisis del datacubo EGIF
Datacubo canónico, variables meteorológicas acumuladas y contrato de datos	Línea de ingesta y construcción del dataset
Validación cruzada espacial por bandas, suelo de ruido por semilla, corrección de consecutive_dry_days, escenario de pronóstico, protocolo de test ciego e integración de todo lo anterior	Fase de consolidación (este documento)